

# [Titel der Ausarbeitung]

[Untertitel der Ausarbeitung]

**Ausarbeitung**

im Studiengang Medieninformatik

Fachbereich Medien  
Hochschule Düsseldorf

Direnc Timur  
Matrikel-Nr.: 123456  
Datum: Juni 2022

Till Pilarczyk  
Matrikel-Nr.: 765335  
Datum: Juni 2022

Prüfer  
Prof. Dr.-Ing. Thomas Rakow

# Eidesstattliche Erklärung

Ich erkläre hiermit an Eides statt, dass ich die vorliegende Ausarbeitung selbständig und ohne unzulässige fremde Hilfe angefertigt habe. Die verwendeten Quellen sind vollständig zitiert. Diese Arbeit wurde weder in gleicher noch ähnlicher Form einem anderen Prüfungsamt vorgelegt oder veröffentlicht. Ich erkläre mich ausdrücklich damit einverstanden, dass diese Arbeit mittels eines Dienstes zur Erkennung von Plagiaten überprüft wird.

*Ort, Datum*

*Direnc Timur*

*Ort, Datum*

*Till Pilarczyk*

## **Kontaktinformationen**

Direnc Timur

direnc.timur@study.hs-duesseldorf.de

—

Till Pilarczyk

till.pilarczyk@study.hs-duesseldorf.de

# Zusammenfassung

[Titel der Ausarbeitung]

Direnc Timur

Dies ist die Zusammenfassung Ihrer Arbeit ...

# Abstract

[Titel der Ausarbeitung]

Direnc Timur

Diese möchten Sie natürlich auch auf Englisch bereitstellen . . .

# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
<b>2</b>	<b>Aktuelle Forschung</b>	<b>2</b>
2.1	Whitepaper künstliche Intelligenz in der Hochschullehre . . . . .	2
2.1.1	Lehren und Lernen mit KI in der Hochschulausbildung . . . . .	2
2.1.2	Lehren und Lernen über KI in der Hochschulausbildung . . . . .	4
2.1.3	KI und Ethik in der Hochschulbildung . . . . .	4
2.1.4	Zukunftsperspektiven für KI in der Hochschulbildung . . . . .	5
2.2	Pass/Fail Prediction with Moodle . . . . .	5
2.2.1	Vorgehen . . . . .	6
2.2.2	Ergebnis . . . . .	6
2.2.3	Fazit . . . . .	7
2.3	AIED . . . . .	8
2.3.1	Notizen . . . . .	9
2.3.2	Vorgehen . . . . .	12
2.3.3	Ergebnis . . . . .	13
2.3.4	Fazit . . . . .	14
<b>3</b>	<b>Einleitung</b>	<b>16</b>
3.1	Exposé . . . . .	16
3.2	Hinweise . . . . .	17
3.3	Inhalt . . . . .	17
3.4	Organisatorisches . . . . .	17
3.5	Bewertungskriterien . . . . .	17
<b>4</b>	<b>Stile</b>	<b>18</b>
4.1	Text . . . . .	18
4.2	Abbildungen und Tabellen . . . . .	18
4.3	Zitieren . . . . .	19
4.4	Listen . . . . .	19
<b>5</b>	<b>Tools</b>	<b>20</b>
5.1	L <sup>A</sup> T <sub>E</sub> X . . . . .	20
<b>6</b>	<b>Infrastruktur</b>	<b>21</b>
6.1	GitLab-Server . . . . .	21
6.2	Versionsverwaltung mit Git . . . . .	21

<b>A</b>	<b>Tipps zu häufig gemachten Fehlern</b>	<b>23</b>
A.1	Abbildungen, Tabellen, Listings, etc. . . . .	23
A.2	Text . . . . .	23
A.3	Diverses . . . . .	23

# Abbildungsverzeichnis

4.1	Logo Hochschule Düsseldorf . . . . .	19
-----	--------------------------------------	----

# Tabellenverzeichnis

4.1	Beispieltabelle . . . . .	19
-----	---------------------------	----



# Abkürzungsverzeichnis

**AIED** Artificial Intelligence in Education

# Kapitel 1

## Einleitung

Aufgabenstellung beschreiben und in DAW einordnen

Historische Entwicklung. Gibt es erst seit 25 Jahren, ist also noch in den Kinderschuhen... es wird viel geforscht Diagramm finden warum das Thema Wichtig ist, wie viele

Hochschulen setzten KIs ein im verlaufe der Jahren ([https : //hochschulforumdigitalisierung.de/sites/default/files/2018-05/HE.pdf](https://hochschulforumdigitalisierung.de/sites/default/files/2018-05/HE.pdf) Seite9)

Als erstes .....

# Kapitel 2

## Aktuelle Forschung

In diesem Kapitel werden einige Paper vorgestellt, in den sich mit dem Thema KI an Hochschulen oder KIs an Hochschulen, die mit Zugriffsdaten arbeiten vorgestellt.

### 2.1 Whitepaper künstliche Intelligenz in der Hochschullehre

#### Kernthemen

1. Lehren und Lernen mit KI in der Hochschulausbildung
2. Lehren und Lernen über KI in der Hochschulausbildung
3. KI und Ethik in der Hochschulausbildung
4. Zukunftsperspektiven für KI in der Hochschulbildung

#### 2.1.1 Lehren und Lernen mit KI in der Hochschulausbildung

Gründe, warum KI eingesetzt werden sollte:

- Verwendung von Daten zur Unterstützung von Studierenden bei der Weiterentwicklung des eigenen Lernverhaltens und Lehrenden bei der Verbesserung ihrer Didaktik.
- Förderung von kritischem und kreativem Denken
- Entdeckung neuer Erkenntnisse durch Analyse von Daten
- Vorzeitige Erkennung von Risiko-Studierenden

Auflistung von Problemen in Studium und Lehre und wie diese Probleme durch KI-Anwendungen adressiert werden können. Beispiele: Begrenzte Tutorzeit von Lehrenden für Studierende, Lösung virtuelle intelligente Assistenten; Aufwändige Bewertung von Texteinreichungen können durch sog. Automated Essay Scoring automatisiert werden.

## Learning Analytics

Learning Analytics als Prozess, um den Prozess des Lernens zu unterstützen. Einteilung von Learning Analytics in drei Varianten: Mikroebene, Mesoebene und Makroebene. Der Prozess kann unterschiedliche Zielgruppen unterstützen, wie Lernende, Lehrende oder auch gesamte Organisationen. Die Varianten beziehen sich dabei auf den Umfang und zeitlichen Kontext des Lernens. In der Mikroebene können Lernende bspw. im Rahmen einer Lernsitzung oder im Verlaufe eines Kurses unterstützt werden. In der Mesoebene können Lernende über ein gesamtes Semester begleitet und Daten kursübergreifend ausgewertet werden.

Learning Analytics könnte auch für die Erkennung von gefährdeten Lernenden eingesetzt werden. Dabei können auf Grundlage der bisherigen Leistungen Abbrüche oder Noten vorhergesagt werden. Mit

Paper listet Herausforderungen, die bei Learning Analytics beachtet werden müssen. Beispiele: Analysen betrachten meist nur einen Ausschnitt des Lernens; Systeme sollten sozialen Kontext berücksichtigen; Berücksichtigung persönlicher Eigenschaften.

## Arten von Künstlichen Intelligenzen in der Hochschulbildung

**Personalisierte adaptive Lernumgebungen (ALU)** Digitale Lernumgebungen für die autonome Lehre gut strukturierter Inhalte. Trennung in Domänenmodell (Fach), Lernermodell und Didaktikmodell. Das Lernermodell betrifft den Zustand des Lernenden und welches Wissen er besitzt. Das Didaktikmodell schlägt auf Basis des Lernenden Lernstrategien und Handlungsempfehlungen vor.

**Chatbots** Lernende können durch Chatbots moderiert und unterstützt werden, wobei sie gleichzeitig Lehrende entlasten.

**Empfehlungssysteme** Empfehlungssysteme sind bislang nur im Auswahlprozess eines Studiengangs im Einsatz.

**Edu-Robots** Meist Begleitungen oder Ersatz für Lehrende in Kursen.

**KI-Schreibbots** Generierung einzigartiger Texte im Hochschulkontext. Birgt die Herausforderung von erschwerter Überprüfbarkeit.

## Veränderung der Betreuung

Zunehmende Vermittlung von kritischem Denken, statt klassischem Wissen. Risiko durch nicht „Allwissenheit“ besteht. Beim Mentoring wichtig ist die Erkennung des Status des Lernenden und damit verknüpfte reaktive Handlungen. Aufteilung des Mentoring in die Phasen Vorbereitung, Lernprozess und Nachbereitung.

- Vorbereitung: Erhebung der Lerninhalte und Planung der Ausgestaltung des Lernprozesses.
- Lernprozess: Ausführung der geplanten individualisierten Aktivitäten zur An eignung der Lerninhalte.

- Nachbereitung: Reflexion des Lernprozesses über Lernerfolg.

Intelligente Tutor- und Lernsysteme führen zur Verbesserung der Lernergebnisse. Fehlende Anwendung von KI, bislang nur Vorhersage von Erfolg und Misserfolg des Lernprozesses.

### **2.1.2 Lehren und Lernen über KI in der Hochschulausbildung**

Es wird erwartet, dass die Nachfrage an Fachkräften im Bereich KI stark wachsen wird → mehr Fokus auf Lehre über KI setzen.

#### **Herausforderungen**

- Uneinheitliches Verständnis über KI.
- Aktuell am meisten Verwendet in Ingenieurwissenschaften, Tendenz interdisziplinär.
- Fehlende Standards digitaler Lernangebote.

#### **Digitale Lehre im Bereich KI**

Anforderung zu mehr digitalen Lernangeboten zu KI. Angebote sollten dabei für mehrere Zielgruppen zugänglich und verwendbar sein. Keine Prämisse für tiefen technischen Hintergrund von Zielgruppen. Lernangebote sollte offen lizenziert sein.

#### **Deutsche Plattformen für digitale Lernangebote zum Thema KI**

- oncampus (TH Lübeck)
- Hamburg Open Online University (HOUU)
- OPEN VHB (virtuelle Hochschule Bayern)
- OpenHPI (Potsdam)
- OER-Content.nrw (Nordrhein-Westfalen)

⇒ insgesamt sehr kleines Angebot an (kostenlosen) Kursen zum Thema KI.

### **2.1.3 KI und Ethik in der Hochschulbildung**

KI und Ethik Motivation: Autonome Systeme können potenziell Menschen schaden. Daher: Anforderung an Transparenz und Verständnis über autonom getroffene Entscheidungen. Herausforderung in der Erklärbarkeit von KI Algorithmen (Forschung im Bereich „Explainable AI“).

**Qualität der Daten** Die Qualität der Daten beeinflusst unmittelbar die Ergebnisse der KI. Gefahr von Diskriminierung / Unterrepräsentation. Neben Algorithmen auch Daten qualitätssichern.

**Sensibilisierung für KI** Analyse der eigenen Daten und anschließende Auswertungen können Misstrauen durch Gefühle von Überwachung und Kontrolle erzeugen. Durch Analyse unterschiedlichster Daten wird zu Fremdbestimmung tendiert. → Sensibilisierung schaffen um damit Akzeptanz und Verständnis zu erhöhen.

### 2.1.4 Zukunftsperspektiven für KI in der Hochschulbildung

**Sam als digitaler Assistent für Lernende** Erzählung aus Sicht eines zukünftigen Studierenden. Sam als digitaler Assistent bietet folgende Funktionalitäten:

- Einführung in Hochschule, Zugang zu Prüfungssystem, Lernmanagementsystem und Bibliothek
- Ansprechpartner für Fragen. Verweis auf externe (Studierendenberatung, Lehrende)
- Mentor für den eigenen Lernprozess unter Berücksichtigung der definierten Lernziele und -stils.
- Anpassung der Lerninhalte an eigenen Wissensstand

**Unterstützung von Lehrenden** Einsatz von KI zur Entlastung von Lehrenden. Dabei übernimmt KI folgende Funktionen:

- Insgesamt Entlastung von Lehrenden.
- Automatisierte Überprüfung von Aufgaben.
- Feedback zur Verbesserung der Didaktik und Lerninhalte des Lehrenden.

Kurzfristig: Vermittlung von Wissen über Systeme an Lehrende. Mittelfristig: Betreuung der Studierenden beim Lernprozess zu kritischem Denken.

## 2.2 Pass/Fail Prediction with Moodle

Rory Quin und Professor Geraldine Gray sind an der „Technological University Dublin“ im Fachbereich für „Informatics and Engineering PhD“ angestellt. Sie haben in dem Artikel „Prediction of student academic performance using Moodle data from a Further Education setting“ welches im Irish Journal of Technology Enhanced Learning im Jahre 2019 veröffentlicht wurde und nach researchgate 14 mal Zitiert worden ist, untersucht ob es Möglich ist anhand von Zugriffsdaten des Lernmanagementsystems Moodle die an einer Hochschule gesammelt wurden, vorhersagen über die Zukünftigen Laufbahn eines Studentens innerhalb eines Kurses zu treffen. Diese Art von Forschung wurde schon von einigen anderen Professoren und Wissenschaftlern untersucht, jedoch immer nur an Universitäten und nie mit Daten von einer Hochschule.

Rory Quin und Professor Geraldine Gray versuchen in dem Paper die Frage, ob es möglich ist, mit Aktivitätsdaten von Moodle, die während der Dauer eines Kurses gesammelt werden vorherzusagen, wie gut ein Student in dem Kurs abschneidet und

damit auch ob dieser den Kurs besteht oder durchfällt zu beantworten. Ebenso versuchen Sie die Frage, ob es möglich ist, mit den selben Daten jedoch nur von den ersten sechs bzw. zehn Wochen vorherzusagen ob ein Student den Kurs bestehen oder durchfallen wird. Dies hat den Grund, dass Dozenten Präventionen einleiten können für Studenten die Gefahr laufen den Kurs nicht zu bestehen. Dies würde nicht nur den Studenten helfen sondern auch der Hochschule und dem Dozenten, denn diese würde langfristig den Zeit und Geld sparen.

### 2.2.1 Vorgehen

Um die Fragen zu beantworten werden Daten von insgesamt 29 Kursen von 9 verschiedenen Modulen im selben Fachbereich und unter der Leitung eines Dozenten genommen. Die Kurse fanden zwischen den Jahren 2011 und 2018 statt. Die Kurse hatten unterschiedlich lange Laufzeiten, der Kürzeste Kurs hat eine Länge von 11 Wochen und der Längste 33 Wochen. Insgesamt konnten so Daten von 690 Kursteilnehmern. Die 690 Kursteilnehmer setzten sich aus insgesamt 410 Studierenden zusammen.

Es werden folgende Zugriffsdaten verwendet, um vorhersagen zu treffen. LISTE VON ZUGRIFFSDATEN /BILDER EINIGE NENNEN

Die erste Klassifizierungsaufgabe besteht darin den Notenbereich der Studierenden hervorzusagen und damit ob diese den Kurs bestehen oder durchfallen. Es gibt folgende Klassen.

1. Early Exit (Abbruch)
2. Fail (Durchgefallen)
3. Pass (Bestanden mit 50% bis 64%)
4. Merit (Bestanden mit 65% bis 79%)
5. Distinction (Bestanden mit 80% bis 100%)

Um die zweite Frage zu beantworten werden die ersten beiden Klassen Early Exit und Fail, sowie die anderen drei Klassen zusammengefasst. Es gibt jetzt nur noch die Klassen Bestanden und Durchgefallen.

Es werden vier verschiedene Algorithmen getestet, um die bestmögliche Vorhersagen zu treffen. Der Random Forest, Gradient Boosting, k Nearest Neighbours und Linear Discriminant Analysis. Es werden sich für die Algorithmen getestet, da diese in anderen Forschungen bereits gute Ergebnisse erzielt. Jeder der Algorithmen wird mit 70% der Daten trainiert. Die restlichen 30% werden benutzt um die Genauigkeit zu überprüfen. Die Genauigkeit wird außerdem mit der „no-information rate“ verglichen. Diese gibt die Genauigkeit an, wenn immer die am häufigsten vorkommende Klasse vorhergesagt wird.

### 2.2.2 Ergebnis

Das Trainieren und Testen mit allen Daten ergibt, dass alle Algorithmen eine ähnliche Genauigkeit haben, wenn es darum geht den Notenbereich vorherzusagen. Sie unterscheiden sich nur in wenigen Prozentpunkten. Der Random Forest Algorithmus trifft

mit einer Genauigkeit von 60,5% Genauigkeit die besten vorhersagen. Wenn es nur darum geht vorherzusagen, ob ein Student den Kurs besteht oder durchfällt hat der Random Forest Algorithmus eine Genauigkeit von 92.2% erreicht. Ach hier schneidet der Algrithmus am besten ab. Mit den 92,2% ist der Algorihmus Signifikant besser als die „no information rate“. Diese liegt aufgrund der Tatsache, das es mehr Studierende gab die Kurse bestanden haben, als die die nicht bestanden haben bei 73.5%. Der Random Forest Algorihmus kann insgesamt 121 von 152 Studierende die den Kurs bestanden haben richtig vorhersagen und 42 von 54 Studierende die den Kurs nicht bestanden haben.

## Frage 2

Das Trainieren und Testen mit Daten von sechs Wochen ergibt, dass kein Algorihmus bessere voraussagen treffen kann, als wenn man die „no information rate“ benutzt, die bei 75,5% liegt. Die unterschiedliche „no information rate“, setzt sich daraus zusammen, dass noch nicht alle Studierenden innerhalb der ersten 6 Wochen des Kurses Moodle benutzen.

Wurden hingegen die Daten der ersten zehn Wochen benutzt kann eine Signifikante verbesserung gegenüber der „no information rate“ erreicht werden. Auch hier schneidet der Random Forest Algorithmus am besten ab. Er erreichte eine Genauigkeit von 82.18% wenn es darum ging zu bestimmen ob studierende den Kurs bestehn oder nict. Die „no information rate“ liegt bei 74.8%.

Am meisten Einfluss auf die Vorhersage, wenn alle Daten oder die der ersten 10 Wochen benutzt wurden, hatte die Anzahl an Tagen an denen sich die Studierenden in den Kurs eingeloggt haben.

### 2.2.3 Fazit

Die Testergebnisse zeigen, dass es möglich ist mithilfe von Zugriffsdaten die von Moodle im laufe eines Kurses gesammelt werden Signifikant bessere vorhersagen über die Noten der Studierenden zu treffen als mit der „no-information rate“. Dabei haben alle Algorithmen gut abgeschlossen und sich nur innerhalb von maximal fünf Prozentpunkten unterschieden. Der Random Forest Algorithmus schließt dabei mit 60.5% am ab. Der Random Forest Algorithmus kann 97% der Studierenden die den Kurs bestehen und 78% der Studierenden die den Kurs nicht bestehen vorhersagen.

Es Reicht jedoch nicht aus am Ende eines Kurses vorherzusagen zu können ob ein Studierender den Kurs besteht oder nicht. Ein frühzeitiger Hinweise welche Studierenden möglicherweise nicht bestehen ,wäre für die Lehrenden Hilfreich, da sie so gezielt Hilfe leisten können. Das Testergebnis zeigt, dass es nicht möglich ist mit Daten von sechs Wochen festzustellen welche Studierenden möglicherweise Durchfallen. Mit den gesammelten Daten von zehn Wochen kann jedoch eine Signifikant bessere Vorhersage getroffen werden als mit der „no-information rate“. Trotzdem können nur weniger als die Hälfte der Studierenden ermittelt werden, die Durchfallen. Dies deutet



darauf hin, dass die Zugriffsdaten von Moodle hilfreich für ein Frühwarnsystem sein können. Mehr Daten wären hilfreich, wenn es darum geht bessere Vorhersagen treffen zu können. Man könnte noch weitere Zugriffsdaten, Ergebnisse von Zwischenabgaben, oder Anzahl an Interaktionen mit anderen Studierenden einzubeziehen.

Das der Reguläre Login so eine hohe Relevanz bei den Vorhersagen hat, zeigt darauf hin, dass diese Student ein besseres Lern und Zeit Management haben. Dies ist ein wichtiger Faktor für den Erfolg.

Abschließend kann gesagt werden, die Zugriffsdaten von Moodle können benutzt werden um ein Frühwarnsystem zu erstellen. Mehr und genauere Daten wären hilfreicher. Die Ergebnisse dieser Studie sollten jedoch noch mit einer größeren Datenmenge wiederholt werden um die Ergebnisse zu bestätigen.

## 2.3 AIED

Professor Niels Pinkwart ist bei der Humbolt-Universität in Berlin als Leiter für „Didaktik der Informatik / Informatik und Gesellschaft“ tätig. Er hat über 250 Publikationen veröffentlicht. Darunter auch den Artikel „Another 25 Years of AIED? Challenges and Opportunities for Intelligent Educational Technologies of the Future“, der im Jahre 2016 im „International Journal of Artificial Intelligence in Education“ veröffentlicht wurde. Dieser Artikel wurde laut der Webseite Springer 45 mal von anderen Autoren zitiert.<sup>1</sup>

In dem Artikel wird versucht die aktuellen Trends und Entwicklungen in der Informatik, der Lehre und der Lehre mit Technologien zu analysieren. Dies hilft dabei Rückschlüsse auf die Weiterentwicklung von Artificial Intelligence in Education (AIED) (dt. Künstliche Intelligenz in der Lehre) in den nächsten 25 Jahren schließen zu können. Basierend auf diesen Trends werden zwei mögliche Zukunftsszenarien vorgestellt. Es gibt eine Utopie und eine Dystopie. Zu letzter werden mögliche Herausforderungen und Chancen für die Entwicklung von AIED Systeme identifiziert, die in den nächsten 25 Jahren entstehen können. Da es nicht möglich ist 25 Jahre in die Zukunft zu schauen, kann der Artikel in Zukunft benutzt werden um zu schauen wie sich AIED entwickelt hat im Vergleich zu dem was gedacht wurde.

Professor Niels nennt sieben Herausforderungen, die in aus den Szenarien hervorgehen. Die folgenden Herausforderungen können als Risiko und als Gelegenheiten gesehen werden.

1. intercultural and global dimensions (dt. Interkulturelle und Globale Dimensionen)

Auch wenn in Zukunft es theoretisch möglich ist jedem Schüler/Student AIED Systeme zukommen zu lassen. Bleibt die Herausforderung das es unterschiedliche Kulturen gibt und jede dieser Kulturen auf eine andere Art und Weise das Wissen vermittelt. Dies liegt zu einem an der Sprache, verschiedene Lehrpläne, die pädagogische Kultur. Dies trifft vor allem auf, wenn typische Schüler-Lehrer Interaktionen auftreten, so wie es bei vielen AIED der Fall ist /sein soll.

Daher ist es notwendig die kulturellen Verschiedenheiten genauer zu erforschen

---

<sup>1</sup><https://link.springer.com/article/10.1007/s40593-016-0099-7>

und AIED Systeme genau zu designen und zu Implementieren, damit mit den Gesammelten Daten nichts falsches angestellt werden kann.

2. practical impact (dt. praktische Auswirkungen)  
Im Moment gibt es schon Kooperationen und benutzte AIED Systeme, dies muss in Zukunft verstärkt werden. Besonders in Schulen. Dafür wird jedoch personal in den Schulen benötigt falls es Probleme mit dem System gibt, oder Personen Hilfe beim Umgang mit diesem brauche, sowie eine dauerhafte erreichbarkeit und benutzbarkeit.
3. privacy (dt. Privatsphäre)  
Wenn privat Firmen AIED Systeme bereitstellen, spielt daten privatsphäre eine besonder Rolle. Es gibt bereits Gesetzte und Regelungen in und zwischen Ländern zu regelung der Datenprivatsphäre, diese werden in Zukunft noch eine Wichtige Rolle spielen. Durch die Strikten regelen wird es auch schwer gewinn mit commerciellen AIED Systemen zu machen, denn wenn man kein Gewinn mit den Daten machen kann. Werbung kann man schlecht schalten, das stört den Lernfluss, Zu Hohe licens kosten, können sich einige Schulen und Lehrinstitutionen nicht leisten. Wenn mit den LernDaten gewinne erzielt werden sollen, müssen Transparente und klar definierte und kontrollierte Regeln in Kraft treten.
4. Interaction methods (dt. Interaktionsmethoden)  
Es muss genau erforscht werden wie Menschen mit den Computersytemen umgehen und versuchen festzustellen wie dies in zukunft aussehen wird, da sich diese stetig ändert und es nicht bringt AIED Systeme für heute zu entwickeln, sondern für morgen.
5. collaboration at scale (dt. Zusammenarbeit im großen Maßstab)
6. effectiveness in multiple domains (dt. Effektivität in verschiedenen Bereichen)
7. role of acAIED in educational technology (dt. Rolle von AIED in Bildungstechnologien)

#### 2.3.1 Notizen

##### Current Trends and Developments

##### Educational trends and Developments Relevant to AIED

Die Dedactic ist ein nicht schnell änders Feld.

Unterschiedliche Kulturen lernen Anders, daher ist es schwierig eine Software zu haben die in vielen Ländern eingesetzt werden kann. Außerdem ist es dadruch schwiierig eine allgegenwörtige, universelle Interaktionsmethode mit der Software/Hardware herzustellen, welche nötig ist damit Lehrende diese in ihere Lehre einbinden können. Ein Weitres Problem ist es, dass Lerherende, die von Ihnen verwendete Technologie verstehen und deren Vorteile kennen müssen, dies passiert jedoch in den seltesten

Fällen. Des Weiteren ist die Schulinfrastruktur nicht ausreichend genug vorhanden um verschiedene Technologien einsetzen pädagogisch sinnvoll einsetzen zu können.

### **Educational technology trends and Developments**

Es wurde herausgefunden, dass es Trends gibt die ein Impact haben auf AIED: Bring Your Own device, Wearable Technology, Adaptive Learning Technologie und IOT

Personalisieren des Lernen durch Learning Analytics (Data driven analytics)

Systeme Kosten und man braucht wahrscheinlich verschiedene Systeme für verschiedenen Kunden. Soll AIED Open Source sein?

### **Two Szenarios**

Das Paper nennt zwei extreme Szenarien die in 25 Jahren eintreten könnten und die uns voraussehen führen sollen, in welche Richtungen AIED gehen kann

#### **Utopie**

Zwei Personen unterhalten sich darüber wie hilfreich deren verwendete Technologie ihnen bei ihrem Lernen geholfen hat, wie sie dadurch Inhalte besser verstanden haben, sich die Anwendungen an deren Lernart angepasst hat und dass sie sie motivieren mit Spielen und sie Spaß beim Lernen haben, sowie auch am Wochenende Hilfe von Digitalen Tutoren haben können und Aufgaben kontrollieren lassen und dass die Lehrer keine Einsicht in die Daten haben und deren Daten nur verwendet wird um ihnen zu helfen und anonymisiert weitergeleitet werden um die Tools zu verbessern. Und dass deren Daten benutzt werden um die Tools zu verbessern.

#### **Distopie**

Zwei Personen sitzen in der Bibliothek und bevorzugen Bücher anstelle von Tools. Das Problem ist hier, dass die Tools nicht für deren Lernart ausgerichtet sind und deren Lehrer diese nicht benutzen. Des Weiteren vermuten die Personen, dass die Lehrer auch besorgt um deren Job ist. Denn in den letzten 10 Jahren haben 50 % der Lehrer von Mathematik und Wissenschaftsfächern ihren Job verloren. Die Tools die benutzt werden besonders in Ethik fächern oder ähnliches sollte mit Vorsicht genutzt werden, da diese die Antworten der Nutzer speichert und weiterverkauft. Es gibt Personen die daher keinen Job gefunden haben. Daher werden auch viele Tools und Foren von wenig Personen benutzt und man bekommt kaum Hilfe.

### **Discussion und Conclusion**

Beide Szenarien folgen den aktuellen Technologie Trends und Herausforderungen, mit denen sich AIED Technologien auseinandersetzen müssen

Challenges: Intercultural and Global Dimensions. Auch wenn in Zukunft es theoretisch möglich ist jedem Schüler/Student AIED Systeme zukommen zu lassen. Bleibt die Herausforderung dass es unterschiedliche Kulturen gibt und jede dieser Kulturen auf eine andere Art und Weise das Wissen vermittelt. Dies liegt zu einem an der Sprache, verschiedene Lehrpläne, die pädagogische Kultur. Dies trifft vor allem auf,

wenn typische Schüler-Lehre Interaktionen auftreten, so wie es bei vielen AIED der Fall ist /sein soll.

Daher ist es notwendig die kulturellen Verschiedenheiten genauer zu erforschen und AIED Systeme genau zu designen und zu implementieren, damit mit den gesammelten Daten nichts Falsches angestellt werden kann.

Challenges: Practical Impact. Im Moment gibt es schon Kooperationen und benutzte AIED Systeme, dies muss in Zukunft verstärkt werden. Besonders in Schulen. Dafür wird jedoch Personal in den Schulen benötigt falls es Probleme mit dem System gibt, oder Personen Hilfe beim Umgang mit diesem brauchen, sowie eine dauerhafte Erreichbarkeit und Benutzbarkeit.

Challenges: Privacy. Wenn Privatfirmen AIED Systeme bereitstellen, spielt die Datenprivatsphäre eine besondere Rolle. Es gibt bereits Gesetze und Regelungen in und zwischen Ländern zur Regelung der Datenprivatsphäre, diese werden in Zukunft noch eine wichtige Rolle spielen. Durch die strikten Regeln wird es auch schwerer Gewinn mit kommerziellen AIED Systemen zu machen, denn wenn man kein Gewinn mit den Daten machen kann. Werbung kann man schlecht schalten, das stört den Lernfluss. Zu hohe Lizenzen kosten, können sich einige Schulen und Lehrinstitutionen nicht leisten. Wenn mit den LernDaten Gewinne erzielt werden sollen, müssen transparente und klar definierte und kontrollierte Regeln in Kraft treten.

Challenges: Interaction Methods. Es muss genau erforscht werden wie Menschen mit den Computersystemen umgehen und versuchen festzustellen wie dies in Zukunft aussehen wird, da sich diese stetig ändert und es nicht bringt AIED Systeme für heute zu entwickeln, sondern für morgen.

Challenges: Collaboration at scale: Derzeit gibt es schon Online Kurse die weltweit genutzt werden, AIED Systeme sollten daher auch die Möglichkeit haben weltweit eingesetzt zu werden.

Challenges: Effectiveness in multiple Domains: ...?? TODO:

Challenges: Role of AIED in educational technology: hmmm ??

Rory Quin und Professor Geraldine Gray sind an der „Technological University Dublin“ im Fachbereich für „Informatics and Engineering PhD “ angestellt. Sie haben in dem Artikel „Prediction of student academic performance using Moodle data from a Further Education setting“ welches im Irish Journal of Technology Enhanced Learning im Jahre 2019 veröffentlicht wurde und nach researchgate 14 mal Zitiert worden ist, untersucht ob es Möglich ist anhand von Zugriffsdaten des Lernmanagementsystems Moodle die an einer Hochschule gesammelt wurden, vorhersagen über die Zukünftigen Laufbahn eines Students innerhalb eines Kurses zu treffen. Diese Art von Forschung wurde schon von einigen anderen Professoren und Wissenschaftlern untersucht, jedoch immer nur an Universitäten und nie mit Daten von einer Hochschule.

Rory Quin und Professor Geraldine Gray versuchen in dem Paper die Frage, ob es möglich ist, mit Aktivitätsdaten von Moodle, die während der Dauer eines Kurses gesammelt werden vorherzusagen, wie gut ein Student in dem Kurs abschneidet und damit auch ob dieser den Kurs besteht oder durchfällt zu beantworten. Ebenso versuchen Sie die Frage, ob es möglich ist, mit den selben Daten jedoch nur von den ersten sechs bzw. zehn Wochen vorherzusagen ob ein Student den Kurs bestehen oder durchfallen wird. Dies hat den Grund, dass Dozenten Präventionen einleiten können für Studenten die Gefahr laufen den Kurs nicht zu bestehen. Dies würde nicht nur den Studenten helfen sondern auch der Hochschule und dem Dozenten, denn diese würde langfristig den Zeit und Geld sparen.

### 2.3.2 Vorgehen

Um die Fragen zu beantworten werden Daten von insgesamt 29 Kursen von 9 verschiedenen Modulen im selben Fachbereich und unter der Leitung eines Dozenten genommen. Die Kurse fanden zwischen den Jahren 2011 und 2018 statt. Die Kurse hatten unterschiedlich lange Laufzeiten, der Kürzeste Kurs hat eine Länge von 11 Wochen und der Längste 33 Wochen. Insgesamt konnten so Daten von 690 Kursteilnehmern. Die 690 Kursteilnehmer setzten sich aus insgesamt 410 Studierenden zusammen.

Es werden folgende Zugriffsdaten verwendet, um vorhersagen zu treffen. LISTE VON ZUGRIFFSDATEN /BILDER EINIGE NENNEN

Die erste Klassifizierungsaufgabe besteht darin den Notenbereich der Studierenden hervorzusagen und damit ob diese den Kurs bestehen oder durchfallen. Es gibt folgende Klassen.

1. Early Exit (Abbruch)
2. Fail (Durchgefallen)
3. Pass (Bestanden mit 50% bis 64%)
4. Merit (Bestanden mit 65% bis 79%)
5. Distinction (Bestanden mit 80% bis 100%)

Um die zweite Frage zu beantworten werden die ersten beiden Klassen Early Exit und Fail, sowie die anderen drei Klassen zusammengefasst. Es gibt jetzt nur noch die Klassen Bestanden und Durchgefallen.

Es werden vier verschiedene Algorithmen getestet, um die bestmögliche Vorhersagen zu treffen. Der Random Forest, Gradient Boosting, k Nearest Neighbours und Linear Discriminant Analysis. Es werden sich für die Algorithmen getestet, da diese in anderen Forschungen bereits gute Ergebnisse erzielt. Jeder der Algorithmen wird mit 70% der Daten trainiert. Die restlichen 30% werden benutzt um die Genauigkeit zu überprüfen. Die Genauigkeit wird außerdem mit der „no-information rate“ verglichen. Diese gibt die Genauigkeit an, wenn immer die am häufigsten vorkommende Klasse vorhergesagt wird.

#### 2.3.3 Ergebnis

Das Trainieren und Testen mit allen Daten ergibt, dass alle Algorithmen eine ähnliche Genauigkeit haben, wenn es darum geht den Notenbereich vorherzusagen. Sie unterscheiden sich nur in wenigen Prozentpunkten. Der Random Forest Algorithmus trifft mit einer Genauigkeit von 60,5% Genauigkeit die besten Vorhersagen. Wenn es nur darum geht vorherzusagen, ob ein Student den Kurs besteht oder durchfällt hat der Random Forest Algorithmus eine Genauigkeit von 92,2% erreicht. Auch hier schneidet der Algorithmus am besten ab. Mit den 92,2% ist der Algorithmus Signifikant besser als die „no information rate“. Diese liegt aufgrund der Tatsache, dass es mehr Studierende gab die Kurse bestanden haben, als die die nicht bestanden haben bei 73,5%. Der Random Forest Algorithmus kann insgesamt 121 von 152 Studierende die den Kurs bestanden haben richtig vorhersagen und 42 von 54 Studierende die den Kurs nicht bestanden haben.

#### Frage 2

Das Trainieren und Testen mit Daten von sechs Wochen ergibt, dass kein Algorithmus bessere Voraussagen treffen kann, als wenn man die „no information rate“ benutzt, die bei 75,5% liegt. Die unterschiedliche „no information rate“, setzt sich daraus zusammen, dass noch nicht alle Studierenden innerhalb der ersten 6 Wochen des Kurses Moodle benutzen.

Wurden hingegen die Daten der ersten zehn Wochen benutzt kann eine Signifikante Verbesserung gegenüber der „no information rate“ erreicht werden. Auch hier schneidet der Random Forest Algorithmus am besten ab. Er erreichte eine Genauigkeit von 82,18% wenn es darum ging zu bestimmen ob Studierende den Kurs bestehen oder nicht. Die „no information rate“ liegt bei 74,8%.

Am meisten Einfluss auf die Vorhersage, wenn alle Daten oder die der ersten 10 Wochen benutzt wurden, hatte die Anzahl an Tagen an denen sich die Studierenden in den Kurs eingeloggt haben.

### 2.3.4 Fazit

Die Testergebnisse zeigen, dass es möglich ist mithilfe von Zugriffsdaten die von Moodle im Laufe eines Kurses gesammelt werden Signifikant bessere Vorhersagen über die Noten der Studierenden zu treffen als mit der „no-information rate“. Dabei haben alle Algorithmen gut abgeschlossen und sich nur innerhalb von maximal fünf Prozentpunkten unterschieden. Der Random Forest Algorithmus schließt dabei mit 60.5% am ab. Der Random Forest Algorithmus kann 97% der Studierenden die den Kurs bestehen und 78% der Studierenden die den Kurs nicht bestehen vorhersagen.

Es reicht jedoch nicht aus am Ende eines Kurses vorherzusagen zu können ob ein Studierender den Kurs besteht oder nicht. Ein frühzeitiger Hinweis welche Studierenden möglicherweise nicht bestehen wäre für die Lehrenden hilfreich, da sie so gezielt Hilfe leisten können. Das Testergebnis zeigt, dass es nicht möglich ist mit Daten von sechs Wochen festzustellen welche Studierenden möglicherweise Durchfallen. Mit den gesammelten Daten von zehn Wochen kann jedoch eine Signifikant bessere Vorhersage getroffen werden als mit der „no-information rate“. Trotzdem können nur weniger als die Hälfte der Studierenden ermittelt werden, die Durchfallen. Dies deutet darauf hin, dass die Zugriffsdaten von Moodle hilfreich für ein Frühwarnsystem sein können. Mehr Daten wären hilfreich, wenn es darum geht bessere Vorhersagen treffen zu können. Man könnte noch weitere Zugriffsdaten, Ergebnisse von Zwischenabgaben, oder Anzahl an Interaktionen mit anderen Studierenden einzubeziehen.

Da der Reguläre Login so eine hohe Relevanz bei den Vorhersagen hat, zeigt darauf hin, dass diese Student ein besseres Lern und Zeit Management haben. Dies ist ein wichtiger Faktor für den Erfolg.

Abschließend kann gesagt werden, die Zugriffsdaten von Moodle können benutzt werden um ein Frühwarnsystem zu erstellen. Mehr und genauere Daten wären hilfreicher. Die Ergebnisse dieser Studie sollten jedoch noch mit einer größeren Datenmenge wiederholt werden um die Ergebnisse zu bestätigen.

*[https://diid.hhu.de/wp-content/uploads/2019/10/DIID-Precis\\_Kieslich-et-al\\_Fin.pdf](https://diid.hhu.de/wp-content/uploads/2019/10/DIID-Precis_Kieslich-et-al_Fin.pdf)*

Fürs Fazit wie viele Leute KI in welchen Bereichen akzeptieren - Keiner will Dropout-detection



# Kapitel 3

## Einleitung

„The user’s going to pick dancing  
pigs over security every time.“

BRUCE SCHNEIER  
(\*1963)

Das Verfassen einer eigenständigen Ausarbeitung ...

### 3.1 Exposé

Bevor eine Ausarbeitung begonnen werden kann, MÜSSEN sich Kandidat/-in und Prüfer auf eine Aufgabenstellung einigen. Als Grundlage dienen hier eigene Ideen des Kandidaten / der Kandidatin und Vorschläge des Prüfers. Diese Aufgabenstellung MUSS vom Kandidaten/von der Kandidatin in ein Exposé überführt werden, welches auf Basis der vorliegenden L<sup>A</sup>T<sub>E</sub>X-Vorlage erstellt und folgende Form / Struktur haben MUSS:

**Kontext und Motivation** Eine inhaltliche Einleitung in das Themengebiet der Arbeit mit Referenzierung der wichtigsten Literatur sowie eine Motivation, z. B. durch Aufarbeitung von Literatur getrieben.

**Ziele** Aufzählung und Kurzbeschreibung konkreter Ziele (im Sinne einer Spezifikation)

**Vorgehen** Eine Beschreibung wie die einzelnen Ziele erreicht werden sollen (im Sinne einer Implementierung) und wie die Zielerreichung validiert werden soll.

**Projektplan** Ein leichtgewichtiger und realistischer Projektplan basierend auf Meilensteinen und untergeordneten Aufgaben, welcher nach Finalisierung des Exposé durch den Kandidaten/die Kandidatin in Gitlab (siehe Abschnitt 6.1) gepflegt werden MUSS.

Das Exposé MUSS explizit (Email, direkte mündliche Absprache, etc.) vom Prüfer akzeptiert werden.

Das Exposé dient im Anschluss als Grundlage für die Einleitung der Ausarbeitung. Dabei sollen explizit die Abschnitte Kontext und Motivation sowie Ziele in der

Einleitung in möglicherweise überarbeiteter Fassung übernommen werden. Zudem MUSS eine Einleitung eine Erläuterung des weiteren Aufbaus der Arbeit beinhalten.

## 3.2 Hinweise

Bitte denken Sie daran, dass Sie die eidesstattliche Erklärung vor Abgabe unterschreiben.

## 3.3 Inhalt

Die Arbeit MUSS – neben dem Hauptteil – nachfolgende Inhalte berücksichtigen:

- Titelseite
- Eidesstattliche Erklärung
- Zusammenfassung und Abstract (Englisch)
- Inhaltsverzeichnis, Abbildungsverzeichnis, Tabellenverzeichnis, Abkürzungsverzeichnis und Literaturverzeichnis
- Einleitung (siehe Abschnitt 3.1)
- Aufarbeitung verwandter und relevanter Literatur unter Angabe der konkreten Vorgehensweise bei der Literaturrecherche
- Kritische Betrachtung der eigenen Arbeit
- Fazit bestehend aus einer reflektierten Zusammenfassung und einem Ausblick

Weiterhin MÜSSEN, falls anwendbar, vom Prüfer vorgegebene Richtlinien für Coding-Style und Code-Dokumentation sowie Gestaltung eingehalten werden.

## 3.4 Organisatorisches

- Es gilt die jeweils aktuelle Prüfungsordnung (§15 in BMI PO vom 04.08.2010 bzw. §15 in MMI PO vom 16.06.2011). Lesen Sie aufmerksam die für Sie geltende Prüfungsordnung und richten Sie sich nach den dort definierten Vorgaben (es sei denn Sie haben mit dem Prüfer eine Abweichung abgesprochen).
- Abzugeben gebunden als Ausdruck (beidseitig bedruckt) und elektronisch als PDF

## 3.5 Bewertungskriterien

Die Bewertung einer Arbeit erfolgt unter anderem auf Grundlage von **Schwierigkeitsgrad**, **wissenschaftlicher Arbeitstechnik**, **ingenieurmäßiger Vorgehensweise**, **Stil** und **Form**.

# Kapitel 4

## Stile

„The wise know their weakness  
too well to assume infallibility;  
and he who knows most, knows  
best how little he knows.“

Thomas Jefferson  
(1743–1826)

Nachfolgend sind einige Beispiele zum Styling von Inhalten aufgeführt. Eine gute Einführung in das Arbeiten mit  $\text{\LaTeX}$  bietet die Ausarbeitung<sup>1</sup> von Jürgens und Feuerstack der FernUniversität in Hagen.

### 4.1 Text

Dies ist ein Beispiel für *kursiven* und **fetten** Text.

Abkürzungen werden in der Datei `acronyms.tex` definiert und können dann vereinfacht genutzt werden. Alle tatsächlich eingesetzten Abkürzungen werden automatisch im Abkürzungsverzeichnis aufgeführt. Eine Abkürzung wird bei der ersten Verwendung zusätzlich ausgeschrieben dargestellt. Ein Beispiel: Das **BSI!** (**BSI!**) stellte fest ... und weiterhin beobachtet das **BSI!** ...

### 4.2 Abbildungen und Tabellen

Abbildung 4.1 zeigt eine einfache Abbildung.

Tabelle 4.1 zeigt eine einfache Tabelle.

---

<sup>1</sup>[https://www.fernuni-hagen.de/imperia/md/content/zmi\\_2010/a026\\_latex\\_einf.pdf](https://www.fernuni-hagen.de/imperia/md/content/zmi_2010/a026_latex_einf.pdf), aufgerufen am 16.06.2017



Abbildung 4.1: Logo Hochschule Düsseldorf

Eins	1
Zwei	2

Tabelle 4.1: Beispieltabelle

## 4.3 Zitieren

Die benötigte Literatur wird in der Datei `literatur.bib` gepflegt. Das Literaturverzeichnis wird automatisch generiert. Dies ist ein Zitat von (**Eckert2014**) ... laut **Eckert2014** ist dieses Vorgehen empfehlenswert.

Der Zitierstil MUSS nach APA (American Psychological Association)<sup>2</sup> Style erfolgen.

## 4.4 Listen

Unsortierte Liste:

- Eins
- Zwei
- Drei

Nummerierte Liste:

1. Element
2. Element
3. Element

---

<sup>2</sup><http://www.apastyle.org/>, abgerufen am 16.06.2017

# Kapitel 5

## Tools

„Man is still the most  
extraordinary computer of all.“

John F. Kennedy  
(1917–1963)

Nachfolgende Hinweise und Empfehlungen zum Einsatz von Tools vereinfachen den Umgang mit  $\text{\LaTeX}$ .

### 5.1 $\text{\LaTeX}$

Das Verfassen von Dokumenten mit  $\text{\LaTeX}$  kann durch unterschiedlichste Tools unterstützt werden. Da  $\text{\LaTeX}$  grundsätzlich textbasiert arbeitet können jegliche Inhalte auch in einem einfachen Texteditor erstellt und angepasst werden.

Mittels unterschiedlichster Editoren kann die Erstellung und Pflege von Dokumenten mit  $\text{\LaTeX}$  vereinfacht werden. Unter Linux bietet der Editor „Kile“<sup>1</sup> eine Vielzahl nützlicher Funktionen. Für Apple OS X und Microsoft Windows ist „Texmaker“<sup>2</sup> empfehlenswert. Unbedingt empfohlen wird die Verwendung einer Rechtschreibprüfung, die typischerweise in den Editoren integriert sind.

---

<sup>1</sup><http://kile.sourceforge.net/>, aufgerufen am 16.06.2017

<sup>2</sup><http://www.xmlmath.net/texmaker/>, aufgerufen am 16.06.2017

# Kapitel 6

## Infrastruktur

„The secret of all victory lies in  
the organization of the  
non-obvious.“

Marcus Aurelius  
(121–180)

Die Erstellung einer Arbeit sollte in einer bereitgestellten Infrastruktur erfolgen, die insbesondere bei der Planung und Verwaltung einer Arbeit unterstützt.

### 6.1 GitLab-Server

Unterschiedliche Dienste, die im Kontext einer Arbeit von Nutzen sind, werden über einen GitLab-Server bereitgestellt. Jeder Kandidat erhält einen persönlichen Zugang und ein eigenes Repository. In diesem Repository werden Dokumente und eigene Inhalte der Arbeit zentral verwaltet und somit dem Betreuer zur Kontrolle übergeben. Der GitLab-Server stellt hierzu in erster Linie ein Repository bereit. Das Repository bzw. eine Versionsverwaltung im Allgemeinen hilft vor allem bei der Verwaltung von textbasierten Dateien, so z. B. Quellcode oder Dokumente in  $\text{\LaTeX}$ .

Zur Planung einer Arbeit und Kontrolle des Fortschritts erfolgt das Projektmanagement digital innerhalb von GitLab. Hierzu werden Milestones und Issues angelegt und während des Projektes gepflegt bzw. Fortschritte kontrolliert. Eine möglichst präzise Projektplanung hilft bei der Vermeidung von etwaigen zeitlichen Engpässen im Laufe der Erstellung einer Arbeit.

### 6.2 Versionsverwaltung mit Git

Die Verwaltung der Arbeit, die mittels  $\text{\LaTeX}$  verfasst wird, und aller zugehörigen Dateien bzw. Dokumente kann auf einfache und sehr transparente Weise mittels einer Versionsverwaltung erfolgen. Als Versionsverwaltung wird Git<sup>1</sup> eingesetzt. Git steht für alle gängigen Betriebssysteme bereit.

---

<sup>1</sup><https://git-scm.com/>, aufgerufen am 16.06.2017

Jegliche Änderungen und Ergänzungen werden von Git erkannt und aufgezeichnet. Erfolgte Änderungen sollten mittels sog. „Commits“ eingepflegt und beschrieben werden. Die Versionsverwaltung erfolgt in erster Linie auf dem lokalen System. Erfolgte Änderungen bzw. Fortschritte sollten – nicht nur als Backup – regelmäßig über den bereitgestellten GitLab-Server dem Betreuer zur Verfügung gestellt werden.

Die Arbeit mit Git kann sowohl auf der Kommandozeile als auch in Applikation mit UI erfolgen. Die Applikation „SourceTree“<sup>2</sup> ermöglicht beispielsweise die komfortable Verwaltung von Git-Repositories.

Grundsätzliche Tipps zum Umgang mit Git liefern die offizielle Dokumentation<sup>3</sup> und das „Git Cheat Sheet“<sup>4</sup>.

Gerade im Zusammenhang mit L<sup>A</sup>T<sub>E</sub>X entstehen viele temporäre Dateien, die nicht in der Versionsverwaltung landen sollten. Dazu sollte eine `gitignore` Konfiguration<sup>5</sup> erstellt werden.

---

<sup>2</sup><https://www.sourcetreeapp.com/>, aufgerufen am 16.06.2017

<sup>3</sup><https://git-scm.com/doc>, aufgerufen am 16.06.2017

<sup>4</sup><https://www.git-tower.com/blog/git-cheat-sheet/>, aufgerufen am 16.06.2017

<sup>5</sup><https://www.gitignore.io/>, aufgerufen am 04.07.2017

# Anhang A

## Tipps zu häufig gemachten Fehlern

### A.1 Abbildungen, Tabellen, Listings, etc.

1. Die Schriftgröße von Text in Abbildungen muss sich nach der Schriftgröße des regulären Textes richten.
2. Alle Abbildungen, Tabellen, Listings, etc. sind mit einer Beschriftung und Nummerierung zu versehen. Im Text muss mit Hilfe der Nummerierung auf die jeweilige Abbildung, Tabelle bzw. das Listing, etc. verwiesen und eine Erläuterung der Abbildung, Tabelle bzw. des Listings verfasst werden.

### A.2 Text

1. Es muss konsistent aus „Wir“ oder „Man“ Perspektive geschrieben werden.
2. Abkürzungen werden einmalig wie in Abschnitt 4.1 beschrieben eingeführt und verwendet.
3. Fachbegriffe müssen eingeführt und definiert werden. Der Fachbegriff kann z.B. einmal *kursiv* gedruckt und danach normal geschrieben werden. Für die Definition und Erklärung sollte einschlägige Literatur verwendet werden.
4. Es muss eine Rechtschreib- und Grammatikprüfung verwendet werden.
5. Es sollte Korrektur durch Dritte durchgeführt werden.
6. Es muss Groß-/Kleinschreibung im Literaturverzeichnis beachtet werden.
7. Es müssen Deutsche Anführungsstriche verwendet werden: „...“

### A.3 Diverses

1. Wenn es sich bei der Arbeit um einen Angriff dreht, dann muss (am Besten am Beginn der Arbeit) die Hackerethik zusammenfassend beschrieben und dabei konkret auf den Angriff bezogen werden.
2. Internetquellen sollen nicht in das Literaturverzeichnis, sondern über eine Fußnote unter Angabe der URL und dem letzten Abrufdatum dokumentiert werden.